



Politechnika Wrocławska

Wydział Elektroniki, Fotoniki i Mikrosystemów

Sterowanie Procesami Ciągłymi

Sprawozdanie nr 4

Identyfikacja obiektu dyskretnego

Prowadzący:
dr hab. inż. Grzegorz Mzyk

Wykonała:
Zuzanna Mejer, 259382

Termin zajęć:
czwartek TP, 9:15

Wrocław, 7 grudnia 2022r.

Spis treści

1	Cel ćwiczenia	2
2	Generowanie danych	2
3	Identyfikacja obiektu	3
4	Błąd estymatora i wielokrotne powtórzenie pomiaru	5
5	Podsumowanie i wnioski	7

1 Cel ćwiczenia

Celem ćwiczenia była identyfikacja obiektu dyskretnego na podstawie wygenerowanych danych oraz późniejsza ocena jakości identyfikacji w zależności od liczby pomiarów.

2 Generowanie danych

Dany jest obiekt dyskretny opisany wzorem:

$$y_k = 3u_k + 2u_{k-1} + 1u_{k-2} + z_k, \quad (1)$$

gdzie z_k, u_k są od siebie niezależne. Wejście u_k jest opisane funkcją *randn*, która generuje liczby o rozkładzie normalnym. Z kolei z_k jest opisane funkcją *rand* - 0,5, która generuje liczby o rozkładzie równomiernym z zakresu $[-0,5 ; 0,5]$. Wykorzystując przedstawiony skrypt (rys. 1), wygenerowano ciąg par (rys. 2):

$$\{(u_k, y_k)\}_{k=3}^N \quad (2)$$

gdzie N to liczba ciągu par. Rozpoczęto od $k = 3$ ze względu na nieznaną wartość wcześniejszych zdarzeń (u_0, u_{-1}) .

```
1 clear all;
2 close all;
3
4 % GENEROWANIE DANYCH
5 i = 1000;
6
7 uk = zeros(i, 1);
8 yk = zeros(i, 1);
9 m = zeros(i, 2);
10
11 for j = 3:1:i
12     uka = randn();
13     uk(j) = uka;
14     zk = rand() - 0.5;
15     yka = 3*uk(j) + 2*uk(j-1) + uk(j-2) + zk;
16     yk(j) = yka;
17     m(j, 1) = uka;
18     m(j, 2) = yka;
19 end
20
```

Rys. 1: Skrypt w Matlabie do wygenerowania danych

Variables - m			
m			
1000x2 double			
	1	2	3
1	0	0	
2	0	0	
3	0.5377	2.0188	
4	-2.2588	-5.2878	
5	0.3188	-3.4262	
6	-0.4336	-2.8752	
7	3.5784	10.6517	
8	-1.3499	3.1441	
9	0.7254	3.0402	
10	0.7147	1.8870	
11	-0.1241	2.1982	
12	1.4090	5.1531	
13	0.6715	4.2441	
14	0.7172	5.3377	
15	0.4889	3.8304	
16	0.7269	3.7679	
17	0.2939	2.4955	
18	0.8884	3.5116	
19	-1.0689	-1.5898	
20	-2.9443	-9.7587	
21	0.3252	-6.1648	
22	1.3703	1.3514	
23	-0.1022	2.6406	
24	0.3192	2.4186	
25	-0.8649	-2.0687	
26	-0.1649	-1.7589	
27	1.0933	2.3398	
28	-0.8637	-0.3896	
29	0.6007	0.8307	
30	-1.1135	-3.0044	

Rys. 2: Fragment wygenerowanego ciągu 1000 par od trzeciego elementu

3 Identyfikacja obiektu

W tej części zakłada się, że nie jest znany dokładny dyskretny opis obiektu (1), a jedynie jego postać:

$$y_k = a_0 \cdot u_k + a_1 \cdot u_{k-1} + a_2 \cdot u_{k-2} + z_k, \quad (3)$$

gdzie a_0, a_1, a_2 to wartości szukane. W celu zidentyfikowania obiektu wygenerowano macierze X_N oraz Y_N zawierające kolejne elementy ciągu par:

$$X_N = \begin{bmatrix} u_3 & u_2 & u_1 \\ u_4 & u_3 & u_2 \\ \dots & \dots & \dots \\ u_N & u_{N-1} & u_{N-2} \end{bmatrix} \quad Y_N = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_N \end{bmatrix} \quad (4)$$

Ze względu na nieznaną wcześniejszych zdarzeń (u_0, u_{-1}), wycięto 2 pierwsze wiersze macierzy X_N , których nie pokazano już w powyższym wzorze.

Do znalezienia a_0, a_1, a_2 przyjęto estymator:

$$\hat{\Theta} = \begin{bmatrix} \hat{a}_0 \\ \hat{a}_1 \\ \hat{a}_2 \end{bmatrix} = (X_N^T \cdot X_N)^{-1} \cdot X_N^T \cdot Y_N \quad (5)$$

W celu wyznaczenia estymatora wygenerowano skrypt w Matlabie (rys. 3). Otrzymane wyniki zostały przedstawione na rys. 4

```

21 % IDENTYFIKACJA
22
23 xn = zeros(i, 3);
24 yn = zeros(i, 1);
25
26 for j = 3:1:i
27     yn(j-2) = m(j, 2);
28     xn(j-2, 1) = m(j, 1);
29     xn(j-2, 2) = m(j-1, 1);
30     xn(j-2, 3) = m(j-2, 1);
31 end
32
33 estymator = inv(xn' * xn) * xn' * yn;
34

```

Rys. 3: Skrypt w Matlabie do wyznaczenia wartości estymowanych

yn	m	estymator
3x1 double		
	1	
1		2.9938
2		1.9914
3		0.9948
4		

yn	m	estymator
3x1 double		
	1	
1		3.0234
2		1.9856
3		1.0057
4		

yn	m	estymator
3x1 double		
	1	
1		3.0041
2		1.9997
3		1.0034
4		

Rys. 4: Oszacowany estymator wartości a_0, a_1, a_2 - 3 próby

Na rys. 4 przedstawione zostały 3 próby wyliczenia estymatora. Przyjął on wartości:

$$\hat{\Theta}_1 \approx \begin{bmatrix} 2,99 \\ 1,99 \\ 0,99 \end{bmatrix} \quad \hat{\Theta}_2 \approx \begin{bmatrix} 3,02 \\ 1,99 \\ 1,01 \end{bmatrix} \quad \hat{\Theta}_3 \approx \begin{bmatrix} 3,00 \\ 2,00 \\ 1,00 \end{bmatrix} \quad (6)$$

Zatem w przybliżeniu: $a_0 = 3, a_1 = 2, a_2 = 1$, co zgadza się z rzeczywistym opisem obiektu dyskretnego (1).

4 Błąd estymatora i wielokrotne powtórzenie pomiaru

Wyznaczono błąd, odejmując wartość rzeczywistą od wartości pochodzącej z identyfikacji, a następnie wyznaczono normę euklidesową otrzymanego wektora:

$$\Delta_N = \text{norm}(\hat{\Theta} - \Theta) \quad (7)$$

Skrypt opisany w poprzednich punktach (rys. 1 3) powtórzono R razy po to, żeby otrzymać wiele estymatorów i żeby móc obliczyć uśredniony błąd estymatora dla danej liczby próbek N :

$$E(N) = \frac{1}{R} \sum_{R=1}^R \Delta_N \quad (8)$$

Ponadto, całość powtórzono jeszcze kilkakrotnie dla różnej liczby próbek $N = 100 : 500 : 10000$ (rys. 5, 6).

```
1 clear all;
2 close all;
3
4 phi = [3;2;1];
5
6 for N = 100:500:10000
7
8     for r = 1:1:10 %5 estymatorow dla kazdej liczby probek
9
10         i = N;
11
12         % GENEROWANIE DANYCH
13         uk = zeros(i, 1);
14         yk = zeros(i, 1);
15         m = zeros(i, 2);
16
17         for j = 3:1:i
18             uka = randn();
19             uk(j) = uka;
20             zk = rand() - 0.5;
21             yka = 3*uk(j) + 2*uk(j-1) + uk(j-2) + zk;
22             yk(j) = yka;
23             m(j, 1) = uka;
24             m(j, 2) = yka;
25         end
26     end
```

Rys. 5: Cały skrypt do wyznaczenia zależności błędu od liczby pomiarów


```

27      % IDENTYFIKACJA
28      xn = zeros(i, 3);
29      yn = zeros(i, 1);
30
31      for j = 3:1:i
32          yn(j-2) = m(j,2);
33          xn(j-2, 1) = m(j,1);
34          xn(j-2, 2) = m(j-1, 1);
35          xn(j-2, 3) = m(j-2, 1);
36      end
37
38      estymator = inv(xn' * xn) * xn' * yn;
39      estymator_r(1, r) = estymator(1);
40      estymator_r(2, r) = estymator(2);
41      estymator_r(3, r) = estymator(3);
42
43      norma_rozniczy(1, r) = norm(estymator_r - phi);
44  end
45      e = 1/r * sum(norma_rozniczy);
46      hold on;
47      plot(N, e, 'b*', 'MarkerSize', 12);
48      hold on;
49      grid on;
50  end
51
52


```

Rys. 6: Cały skrypt do wyznaczenia zależności błędu od liczby pomiarów - kontynuacja

Dzięki temu narysowano jaki jest wpływ liczby pomiarów na średni błąd estymatora (rys. 7, 8).



Rys. 7: Zależność średniego błędu estymatora od liczby pomiarów dla 5 wygenerowanych estymatorów



Rys. 8: Zależność średniego błędu estymatora od liczby pomiarów dla 10 wygenerowanych estymatorów

5 Podsumowanie i wnioski

Po wykonaniu ćwiczenia sformułowano następujące wnioski:

- Identyfikacja obiektu przebiegła poprawnie i pozwoliła na dokładne wyznaczenie parametrów opisujących badany obiekt.
- Wyznaczone wartości estymatora niewiele różniły się od rzeczywistych wartości, a po zaokrągleniu były z nimi identyczne.
- Średni błąd estymatora identyfikacji jest zależny od liczby pomiarów. Im więcej pomiarów, tym błąd estymatora dąży do 0. Na rys. 8 dla 100 pomiarów błąd $E(N) \approx 0,075$, podczas gdy dla 10 000 pomiarów zmalał do wartości $E(N) \approx 0,01$.
- Funkcja błędu estymatora od liczby próbek przypomina funkcję eksponencjalną.